



**Universidad de Buenos Aires
Facultad de Ciencias Económicas
Carrera de Actuario**

Modelado de la mortalidad mediante algoritmos de aprendizaje automático

Aplicación a una cartera de rentas vitalicias en una aseguradora chilena

Alumno: D'Atri Rafael

N.º de Registro: 889.250

Correo electrónico: datri.rafa@gmail.com

Tutor: Act. Pablo Caviezel

Correo electrónico: pcaviezel@economicas.uba.ar

Asignatura: Profesor regular adjunto de Análisis Numérico y profesor regular asociado del Grupo de Asignaturas del Área Actuarial.

Firma del tutor:

Índice

1. Introducción.....	4
2. Justificación del Problema.....	5
3. Antecedentes	6
3.1 Origen y Evolución de las Tablas de Mortalidad	6
3.2 Tablas de Mortalidad Ajustadas por Experiencia	7
3.3 Modelos Estocásticos de Mortalidad.....	7
3.4 La Incorporación del Aprendizaje Automático	8
4. Objetivos.....	8
4.1 Objetivo General	8
4.2 Objetivos Específicos	8
4.3 Preguntas de Investigación	9
4.4 Hipótesis	9
4.4.1 Hipótesis principal	9
4.4.2 Hipótesis secundarias	10
5. Marco Teórico.....	10
5.1 Tasas Centrales de Mortalidad.....	10
5.2 Redes Neuronales.....	12
5.3 XGBoost	16
5.3 Suavizamiento Whittaker-Henderson	17
5.4 Método Delta para IC	18
5.5 Bandas de Wilson	19
5.6 Métricas de Machine Learning.....	20
5.7 Synthetic Minority Over-sampling Technique	23
6. Metodología y Técnicas	24
6.1 Análisis Exploratorio de Datos	24
6.2 Redes Neuronales Artificiales	27
6.3 XGBoost	29
6.4 Tasas de Mortalidad.....	29
6.5 Resultados	32
7. Fuentes de Información	36
8. Consideraciones Éticas	36

9. Conclusión.....	37
10. Referencias Bibliográficas	38
11. Anexo.....	40
I: Análisis Exploratorio de Datos	40
II: XGBoost Model	41
III: SMOTE	42
III: Función ReLU	43
IV: Función Sigmoide.....	43
V: Supuesto $\mathbf{I}x$ Exponencial	43
VI: Teorema Central del Límite	44
VII: Gompertz–Makeham.....	45
VII: Código Área curva $\mathbf{I}x$	47

1. Introducción

La estimación precisa de la mortalidad constituye uno de los desafíos centrales en el ámbito actuarial, especialmente en productos de largo plazo como las rentas vitalicias. Las tablas de mortalidad, que resumen las probabilidades de fallecimiento por edad y sexo, son herramientas esenciales para la determinación de primas, reservas matemáticas y para la preservación de la solvencia técnica de las aseguradoras. Su importancia trasciende lo actuarial, siendo también de gran interés para demógrafos y profesionales vinculados a la salud pública y al desarrollo económico y social, dado que constituyen un instrumento fundamental para el análisis de la dinámica poblacional (Ortega, 2004).

El concepto de tabla de vida tiene raíces históricas que se remontan a John Graunt, quien en 1662 presentó información referida a una generación de personas cuya cantidad disminuía progresivamente por efecto de las defunciones, marcando un avance significativo respecto de la simple tasa bruta de mortalidad. Posteriormente, Edmund Halley elaboró en 1693 sus tablas de vida a partir de registros de nacimientos y defunciones de la ciudad polaca de Breslau. Con el tiempo, el desarrollo metodológico llevó a la construcción de tablas modernas como la de Milne (1815) para la ciudad de Carlisle, que incorporó tanto las defunciones como la población expuesta al riesgo de muerte. Desde entonces, las tablas de mortalidad se han construido para la mayoría de los países del mundo, aplicando cada vez metodologías más refinadas y adaptadas a las características de cada población (Ortega, 2004).

Tradicionalmente, estas tablas se han elaborado a partir de bases poblacionales bajo supuestos ideales —poblaciones cerradas, nacimientos constantes, estabilidad en la distribución de muertes por edad— que no siempre se cumplen en la práctica, especialmente en carteras específicas de asegurados. Modelos estocásticos como el de Lee y Carter (1992) introdujeron avances al permitir la incorporación de tendencias temporales, pero continúan requiriendo estructuras funcionales predefinidas y presentan limitaciones para capturar fenómenos complejos en carteras reales (Basellini, Camarda & Booth, 2023).

En los últimos años, el aprendizaje automático ha abierto nuevas posibilidades para modelar la mortalidad sin necesidad de imponer formas funcionales rígidas. Inicialmente, esta tesis planteó la utilización de redes neuronales artificiales (RNA), dada su flexibilidad y capacidad de capturar relaciones no lineales entre múltiples variables (Haykin, 2009). Sin embargo, durante el desarrollo se evaluaron otras alternativas. Este análisis motivó la adopción de XGBoost, un algoritmo de *gradient boosting* que ha demostrado gran capacidad predictiva en contextos de clasificación binaria y que se adapta bien a datos estructurados y heterogéneos (Chen & Guestrin, 2016).

El objetivo central de este trabajo es generar una tabla de mortalidad empírica ajustada a la experiencia de una cartera de rentas vitalicias en Chile, utilizando Redes Neuronales Artificiales y XGBoost para estimar probabilidades individuales de fallecimiento y compararlas con las tasas de una tabla regulatoria de referencia. Con ello, se busca evaluar si el uso de técnicas de *machine learning* permite mejorar la precisión de las estimaciones y reducir los sesgos derivados del uso de tablas estándar.

2. Justificación del Problema

El envejecimiento poblacional constituye uno de los desafíos más significativos del siglo XXI, tanto para los sistemas de seguridad social como para el sector asegurador. El aumento sostenido de la esperanza de vida prolonga el tiempo durante el cual las compañías de seguros deben cumplir obligaciones asociadas a productos de largo plazo, como las rentas vitalicias. En este contexto, contar con estimaciones precisas de la mortalidad resulta esencial para garantizar la solvencia técnica y una adecuada gestión del riesgo biométrico.

Históricamente, las aseguradoras han recurrido a tablas de mortalidad estándar publicadas por organismos oficiales o asociaciones profesionales, como las tablas CSO, GAM, MI o RV, ampliamente utilizadas en América Latina. Sin embargo, al estar construidas a partir de poblaciones agregadas —frecuentemente nacionales o internacionales—, estas tablas pueden no reflejar con exactitud la experiencia real de carteras específicas. La desconexión entre los supuestos teóricos y los datos observados en la práctica puede derivar en una sobreestimación o subestimación sistemática de las tasas de fallecimiento, afectando de forma directa el cálculo de primas, reservas matemáticas y la evaluación del riesgo asegurado (Society of Actuaries, 2015).

Con el objetivo de reducir esta brecha, los estudios de experiencia se presentan como una herramienta clave para estimar tasas empíricas de mortalidad a partir de datos reales de asegurados. Estos estudios permiten capturar particularidades de la cartera, como la edad de inicio de la cobertura, el sexo, la duración del contrato, la condición del asegurado (causante o beneficiario) y factores sociodemográficos como la región de residencia. Según la Society of Actuaries (SOA), la alineación de los supuestos actuariales con la experiencia observada mejora la precisión de reservas, tarifas y márgenes de riesgo (SOA, 2015; Chan et al., 2018).

No obstante, su implementación enfrenta retos importantes: la calidad y consistencia de los datos disponibles, las limitaciones de muestras finitas y la rigidez de los métodos clásicos de graduación y proyección —como Gompertz, Makeham o Lee-Carter (1992)—, que requieren estructuras funcionales predefinidas y suelen suponer una evolución temporal homogénea de la mortalidad. Estos enfoques pueden ser insuficientes cuando se pretende capturar fenómenos complejos como mejoras abruptas en la longevidad, efectos de cohorte o heterogeneidades estructurales en la población asegurada (Li et al., 2004; Bergeron-Boucher et al., 2017).

El avance de las técnicas de aprendizaje automático ha abierto nuevas posibilidades para superar estas limitaciones. En este trabajo se aplicaron dos metodologías complementarias:

por un lado, las redes neuronales artificiales (RNA), que constituyen un enfoque flexible y no paramétrico capaz de modelar relaciones no lineales entre múltiples variables; y por otro, el algoritmo Extreme Gradient Boosting (XGBoost), reconocido por su alta capacidad predictiva, robustez ante datos heterogéneos y desbalanceados, y un nivel de interpretabilidad relativamente superior frente a otros métodos de machine learning.

En este enfoque, el modelo estima para cada asegurado la probabilidad anual de fallecimiento, incorporando múltiples características relevantes. Posteriormente, dichas probabilidades se agrupan por edades para obtener q_x específicas de cartera, que se comparan con la experiencia real y con una tabla de mortalidad de referencia. Esta comparación permite evaluar no solo el desempeño predictivo del modelo, sino también su utilidad en el desarrollo de tablas empíricas y en el ajuste de supuestos actuariales a la realidad observada.

El presente trabajo se justifica, por tanto, en la necesidad de desarrollar metodologías más precisas, adaptables y robustas para la estimación de la mortalidad en carteras reales, contribuyendo a una mejor gestión del riesgo y a una mayor solidez técnica en el cálculo de reservas y tarifas de productos de largo plazo como las rentas vitalicias.

3. Antecedentes

3.1 Origen y Evolución de las Tablas de Mortalidad

El estudio sistemático de la mortalidad tiene sus orígenes en el siglo XVII, con los primeros esfuerzos por cuantificar el riesgo de fallecimiento según la edad. En 1662, John Graunt publicó un análisis sobre los registros de defunciones en Londres, considerado uno de los primeros estudios demográficos. Su tabla, aunque rudimentaria y sin diferenciación por sexo, introdujo la idea de asociar una probabilidad de muerte a cada grupo etario, sentando las bases del análisis actuarial.

Pocos años después, Halley (1693) elaboró una tabla más estructurada a partir de datos de la ciudad de Breslau y fue el primero en aplicar dichos datos al cálculo del valor actual de una renta vitalicia. Durante el siglo XVIII, autores como Struyck y Kersseboom introdujeron avances metodológicos, siendo los primeros en segmentar las tablas por sexo, lo que permitió estimaciones más precisas debido a diferencias estructurales en la mortalidad entre hombres y mujeres.

Durante el siglo XIX y buena parte del XX, las tablas de mortalidad se construyeron utilizando métodos deterministas, a menudo con funciones analíticas como las de Gompertz o Makeham, y basadas en registros vitales o datos censales. Estas tablas asumían una evolución estable y homogénea de la mortalidad, sin contemplar fenómenos disruptivos, efectos de cohorte ni heterogeneidad estructural (Babel, Bomsdorf, & Schmidt, 2008).

3.2 Tablas de Mortalidad Ajustadas por Experiencia

La calidad y el nivel de segmentación de las tablas de mortalidad en América Latina varían significativamente entre países, dependiendo de su tradición censal y capacidad estadística. Algunas jurisdicciones han desarrollado tablas refinadas a partir de registros demográficos extensos, mientras que otras enfrentan limitaciones metodológicas derivadas de la escasa disponibilidad de datos fiables.

En Chile, la normativa previsional vigente establece explícitamente qué tablas deben utilizarse para el cálculo de rentas vitalicias. Según el Decreto Ley N.º 3.500 (artículos 55 y 65), la Superintendencia de Pensiones distingue tres tipos de tablas según la condición del asegurado: causante, beneficiario o inválido, con desagregación adicional por sexo. Esta segmentación permite capturar diferencias estructurales en las probabilidades de supervivencia entre grupos y mejorar la precisión de las estimaciones. Asimismo, la normativa autoriza la aplicación de factores de ajuste para adaptar las tablas a la experiencia observada en cada compañía, reforzando el vínculo entre regulación y evidencia empírica.

En contraste, en Argentina no existe una disposición normativa específica que determine qué tabla utilizar para cada grupo de asegurados en productos como las rentas vitalicias. Sin embargo, en seguros individuales de vida, la Resolución SSN N.º 697/2018 establece el uso de la tabla CSO 2001 al 74 % de su valor base, permitiendo además un ajuste adicional de hasta el 25 %. Esto demuestra un reconocimiento por parte del regulador de la necesidad de calibrar las tablas a partir de la experiencia real, aun cuando el marco normativo sea menos específico que el chileno.

La lógica subyacente a estos enfoques remite al concepto de estudios de experiencia, que permiten construir tablas adaptadas a las características particulares de una cartera asegurada. Aunque su formalización como herramienta sistemática es relativamente reciente, ya en la década de 1980 se destacaba la importancia de utilizar datos reales de fallecimientos para estimar probabilidades de muerte (Bowers, Gerber, Hickman, Jones, & Nesbitt, 1997). En las últimas décadas, factores como el envejecimiento poblacional, cambios en los estilos de vida y eventos disruptivos —como la pandemia de COVID-19— han desafiado la capacidad de las tablas tradicionales para reflejar adecuadamente la evolución de la mortalidad. Como señala Pitacco (2009), la longevidad constituye hoy uno de los principales riesgos técnicos en productos como las rentas vitalicias, donde pequeños errores en la estimación pueden tener impactos significativos en la solvencia de las aseguradoras.

En este contexto, los estudios de experiencia adquieren una relevancia estratégica al permitir la elaboración periódica de tablas ajustadas, considerando no solo la edad y el sexo, sino también factores temporales, socioeconómicos y estructurales.

3.3 Modelos Estocásticos de Mortalidad

Hasta los años ochenta, las proyecciones de mortalidad se basaban en extrapolaciones simples o juicio experto. El modelo de Lee y Carter (1992) introdujo un enfoque estocástico que descompone logarítmicamente las tasas de mortalidad en componentes de edad y

tiempo, proyectando el factor temporal como una serie de tiempo. Si bien este modelo representó un avance metodológico, estudios posteriores identificaron sesgos y limitaciones, especialmente en contextos con estructuras etarias complejas o shocks demográficos (Booth, Hyndman, & Tickle, 2006; Basellini, Camarda, & Booth, 2023).

3.4 La Incorporación del Aprendizaje Automático

El desarrollo de técnicas de aprendizaje automático ha transformado el modelado de mortalidad al permitir estimar tasas sin supuestos funcionales estrictos. Entre ellas, las redes neuronales artificiales (RNA) ofrecen flexibilidad para capturar relaciones no lineales entre variables como edad, sexo, región o condición del asegurado, y presentan la ventaja de poder reentrenarse con nuevos datos a medida que evoluciona la experiencia (Booth, Hyndman, & Tickle, 2014).

De manera complementaria, en el ámbito actuarial también han cobrado relevancia los algoritmos de ensamble, en particular Extreme Gradient Boosting (XGBoost), dada su capacidad para manejar datos tabulares, capturar interacciones complejas entre covariables y adaptarse a distribuciones desbalanceadas. Diversas investigaciones destacan su aplicabilidad en la predicción de eventos binarios como la mortalidad y en la construcción de tablas ajustadas a experiencias específicas, constituyendo una alternativa robusta frente a metodologías tradicionales (Chen & Guestrin, 2016; Richman, Brooks, & Charpentier, 2020).

En este marco, la presente investigación adopta simultáneamente RNA y XGBoost para estimar probabilidades individuales de fallecimiento en una cartera de rentas vitalicias, integrando técnicas de calibración y validación orientadas a la elaboración de tablas de mortalidad ajustadas a la experiencia observada.

4. Objetivos

4.1 Objetivo General

Desarrollar modelos predictivos basados en redes neuronales artificiales (RNA) y en el algoritmo XGBoost para estimar tasas empíricas de mortalidad ajustadas a la experiencia de una cartera de causantes y beneficiarios hombres en rentas vitalicias en Chile, comparando sus resultados con la tabla regulatoria CB-H-2020, con el propósito de evaluar mejoras en la precisión y en la reducción de sesgos en la estimación del riesgo biométrico.

4.2 Objetivos Específicos

- I. Analizar, depurar y preparar la base de datos provista por la aseguradora, corrigiendo inconsistencias, valores faltantes y formatos incorrectos (por ejemplo, en la variable *Edad_Inicio*) para garantizar la calidad y coherencia de la información.
- II. Realizar un análisis exploratorio de las variables relevantes (edad de inicio, condición del asegurado, zona geográfica, entre otras), identificando patrones preliminares y su relación con la probabilidad de fallecimiento.

- III. Implementar y entrenar modelos predictivos basados en redes neuronales artificiales (RNA) y en XGBoost, optimizando sus hiperparámetros mediante validación cruzada y evaluando su desempeño con métricas como MAE, F1-score y AUC.
- IV. Comparar las probabilidades de fallecimiento (q_x) estimadas por los modelos con las de la tabla regulatoria CB-H-2020, analizando diferencias por grupo etario y su impacto en la representación de la experiencia real.
- V. Construir tablas empíricas de mortalidad a partir de las estimaciones de los modelos, orientadas a su uso como insumo en la valuación actuarial de rentas vitalicias y otros productos de largo plazo.
- VI. Analizar las implicancias técnicas y operativas de incorporar modelos de *machine learning* en el modelado de mortalidad, evaluando ventajas, limitaciones y su complementariedad con los enfoques actuariales tradicionales.

4.3 Preguntas de Investigación

El presente trabajo busca responder a los siguientes interrogantes:

Pregunta central

¿Las probabilidades de fallecimiento específicas de cartera (q_x) para causantes y beneficiarios hombres, estimadas mediante modelo de *machine learning* entrenado con datos históricos de rentas vitalicias, presentan un menor error absoluto medio (MAE) que las probabilidades derivadas de la tabla de mortalidad regulatoria vigente (CB-H-2020)?

Preguntas derivadas

- I. ¿Existen diferencias estadísticamente significativas entre las tasas de mortalidad generadas por XGBoost, las generadas por Redes Neuronales Artificiales y las de la tabla regulatoria, particularmente en ciertos grupos etarios?
- II. ¿El modelo XGBoost logra métricas de desempeño (F1-score y AUC) superiores en comparación con Redes Neuronales Artificiales?
- III. ¿Es factible integrar modelos de *machine learning* al proceso actuarial tradicional de construcción de tablas de mortalidad, complementando los métodos regulatorios vigentes?

4.4 Hipótesis

4.4.1 Hipótesis principal

Las probabilidades de fallecimiento específicas de cartera (q_x) para causantes y beneficiarios hombres, estimadas mediante un modelo de aprendizaje automático (RNA y XGBoost) entrenado con datos históricos de rentas vitalicias, presentarán un menor error absoluto medio (MAE) respecto de las tasas observadas que las probabilidades derivadas de la tabla de mortalidad regulatoria vigente (CB-H-2020), generando estimaciones más representativas de la experiencia real y reduciendo el sesgo en la estimación.

4.4.2 Hipótesis secundarias

- H1: Las tasas de mortalidad generadas por RNA y XGBoost presentan diferencias estadísticamente significativas respecto de las de la tabla regulatoria, particularmente en determinados grupos etarios.
- H2: s redes neuronales artificiales alcanzan métricas de desempeño (MAE, F1-score y AUC) levemente superiores a XGBoost, aunque sin diferencias sustanciales en términos prácticos.
- H3: La implementación de modelos de machine learning para el modelado de mortalidad es factible en el contexto actuarial y puede integrarse como complemento de las herramientas tradicionales, aportando flexibilidad y capacidad de ajuste a experiencias específicas.

5. Marco Teórico

5.1 Tasas Centrales de Mortalidad

La tasa central de mortalidad $m(x; 0; n)$ o m_x^n para el intervalo $[x, x + n)$ se define como:

$$m_x^n = \frac{d_x^n}{L_x^n}$$

En donde $d(x; 0; n)$ o d_x^n representa el número de fallecimientos observados (o predichos por el modelo) en el intervalo $[x, x + n)$. L_x^n representa el tiempo total vivido por la cohorte de individuos que ingresan al intervalo de edades $[x, x + n)$. Formalmente, se define como el área bajo la función de supervivientes l_t dentro de dicho intervalo:

$$L_x^n = \int_x^{x+n} l_t dt$$

Esta expresión corresponde con el tiempo total vivido y siempre que se disponga de la forma funcional de la curva l_t , el área podrá calcularse de forma exacta. No obstante, en la práctica no se cuenta con la expresión funcional continua de l_t , sino con valores discretos derivados de tablas de mortalidad o en nuestro caso de valores observados, en consecuencia, es necesario recurrir a aproximaciones.

Una de las más utilizadas consiste en descomponer el tiempo vivido en dos componentes:

- I. Tiempo de los sobrevivientes hasta el final del intervalo: corresponde a las l_{x+n} personas que alcanzan la edad $x + n$, que debido a que se mantuvieron con vida vivieron los n años del intervalo.

$$\text{tiempo de los sobrevivientes} = n \cdot l_{x+n}$$

- II. Tiempo de los fallecidos dentro del intervalo: corresponde a las d_x^n personas que mueren en el lapso $[x, x + n)$. Suponiendo que, en promedio, cada una de estas personas sobrevive k_x^n , el tiempo total vivido por ellas es:

$$\text{tiempo de los fallecidos} = k_x^n d_x^n$$

Sumando ambas expresiones resulta:

$$L_x^n = n \cdot l_{x+n} + k_x^n d_x^n$$

Es claro que, si la función de sobrevivencia l_x tuviera una expresión analítica conocida, el tiempo vivido L_x^n podría determinarse exactamente mediante la resolución de la integral respectiva. En la práctica esto rara vez ocurre, ya que la función suele estar disponible únicamente en puntos discretos —correspondientes a edades enteras 0,1,2, ... — por lo que resulta necesario emplear métodos de aproximación.

En las tablas completas, donde el intervalo de edades considerado es de una unidad, la estimación del tiempo vivido es suficientemente precisa si se supone que la función l_x se comporta de manera lineal en cada tramo $[x, x + 1)$. Sin embargo, al ampliar la longitud del intervalo, el error de este procedimiento se incrementa, volviendo inadecuada la aplicación de la regla de los trapecios.

Cuando se trata de tablas abreviadas, usualmente construidas en grupos quinquenales, el procedimiento más utilizado para el cálculo del tiempo vivido se apoya en la tasa central de mortalidad m_x^5 . En tal caso, se cumple que:

$$m_x^5 = \frac{d_x^5}{L_x^5} \Rightarrow L_x^5 = \frac{d_x^5}{m_x^5}$$

De esta manera conociendo la tasa central de mortalidad, que es la función básica en la construcción de la tabla de vida, una vez obtenida la probabilidad de muerte y las defunciones, se puede calcular el tiempo vivido. Sin embargo, este método no siempre es factible, en particular cuando no se dispone de dicha tasa.

En estos casos, Greville y Keyfitz sugieren una alternativa basada en la regla de los trapecios modificada, cuya expresión, para intervalos de cinco años, es la siguiente:

$$L_x^5 = \frac{5}{2} (l_x + l_{x+5}) + \frac{5}{24} (d_{x+5}^5 - d_{x-5}^5)$$

A continuación, un gráfico que permite ilustrar lo mencionado en donde la función de supervivencia utilizada fue bajo el modelo de Gompertz–Makeham con parámetros: $a = 5.5 \times 10^{-5}$, $b = 0.095$, $c = 1.5 \times 10^{-4}$. (véase: VII: Gompertz–Makeham)




Ilustración I: Aproximación vía Greville y Keyfitz del tiempo vivido bajo una función de supervivencia Gompertz–Makeham. Elaboración propia, véase: VII: Código Área curva l_x

Una vez obtenidas las tasas centrales de mortalidad m_x^n a partir del cálculo de los tiempos vividos L_x^n , el siguiente paso consiste en derivar las probabilidades de fallecimiento q_x^n o $q(x; 0; n)$. Ortega (1987) señala que esta relación depende del supuesto adoptado sobre la forma de variación de la función de supervivencia l_x dentro del intervalo $[x, x+n)$. En particular, cuando l_x se supone decreciente de manera exponencial, la relación entre ambas medidas se expresa como:

$$q_x^n = 1 - e^{-n \cdot m_x^n}$$

Véase: V: Supuesto l_x Exponencial

5.2 Redes Neuronales

Las redes neuronales artificiales (RNA) son algoritmos de aprendizaje supervisado inspirados en el funcionamiento de las redes neuronales biológicas. Su estructura está compuesta por un conjunto de nodos o *neuronas artificiales* organizadas en capas: una capa de entrada, una o más capas ocultas y una capa de salida. Cada conexión entre neuronas tiene un peso asociado, que determina la influencia relativa de cada entrada sobre el resultado final (Haykin, 2009).

La elección de esta arquitectura obedece a criterios empíricos: capas más grandes permiten modelar relaciones más complejas, aunque a costa de mayor riesgo de sobreajuste. Cada neurona recibe entradas $x_1, x_2, \dots, x_n$ y computa una combinación lineal ponderada de las mismas mediante pesos $w_1, w_2, \dots, w_n$ y un término de sesgo b :

$$z = \sum_{i=1}^n w_i x_i + b = w^T x + b$$

A esta combinación lineal se le aplica una función de activación que introduce no linealidad en el modelo. En las capas ocultas se utiliza la función ReLU (Rectified Linear Unit), definida como:

$$\text{ReLU}(z) = \max(0, z)$$




Ilustración II: Función ReLU. Elaboración propia. Referir código en: III: Función ReLU

```
import numpy as np
import matplotlib.pyplot as plt

# Define the ReLU function
def ReLU(z):
    return np.maximum(0, z)

# Generate values for z
z = np.linspace(-10, 10, 400)
y = ReLU(z)

# Plot the sigmoid function
plt.figure(figsize=(8, 5))
plt.plot(z, y, label=r'$ReLU(z) = \max(0, z)$', color='blue')
plt.title('ReLU Function')
plt.xlabel('z')
plt.ylabel(r'$ReLU(z)$')
plt.legend()
plt.grid(True)
plt.tight_layout()
plt.show()
```

IV: Función Sigmoide

Esta función ha demostrado ser altamente eficiente en redes profundas, ya que mitiga el problema del desvanecimiento del gradiente, reduce la complejidad computacional y favorece una convergencia más rápida durante el entrenamiento (Nair & Hinton, 2010). Su comportamiento simple —anulando valores negativos y manteniendo los positivos sin alterar— introduce una no linealidad esencial en la red sin saturar los gradientes.

La información fluye capa por capa en lo que se conoce como propagación hacia adelante (forward propagation) para culminar en la última capa de salida que contiene una sola neurona. Esta neurona aplica la función sigmoide que transforma el valor de z en un número que vive en el intervalo $[0,1]$

$$a = \sigma(z) = \frac{1}{1 + e^{-z}}$$

Este valor se interpreta como la probabilidad estimada de que el individuo fallezca. Luego, se establece un umbral de decisión (habitualmente 0.5) para convertir esta probabilidad en una predicción binaria: si $\sigma(z) \geq 0.5$, la red predice 1 (fallecido); en caso contrario, predice 0 (no fallecido).




Ilustración III: Función Sigmoide. Elaboración propia. Véase código en III: Función ReLU

```

import numpy as np
import matplotlib.pyplot as plt

# Define the ReLU function
def ReLU(z):
    return np.maximum(0, z)

# Generate values for z
z = np.linspace(-10, 10, 400)
y = ReLU(z)

# Plot the sigmoid function
plt.figure(figsize=(8, 5))
plt.plot(z, y, label=r'$ReLU(z) = \max(0, z)$', color='blue')
plt.title('ReLU Function')
plt.xlabel('z')
plt.ylabel(r'$ReLU(z)$')
plt.legend()
plt.grid(True)
plt.tight_layout()
plt.show()

```

IV: Función Sigmoide

Para que el modelo aprenda a clasificar correctamente los datos, es necesario definir una función de pérdida que cuantifique el error cometido al comparar las predicciones del modelo con los valores reales observados. Esta función orienta el proceso de ajuste de los pesos y sesgos internos de la red neuronal. En la etapa de entrenamiento, comúnmente se destina el 80 % del conjunto de datos, reservando el 20 % restante para evaluar la capacidad predictiva del modelo sobre datos no vistos.

La elección de la función de pérdida resulta fundamental en el proceso de entrenamiento de una red neuronal, ya que determina cómo se penalizan las discrepancias entre las predicciones del modelo y los valores reales observados. Dependiendo del tipo de problema —regresión, clasificación binaria o multiclase— se utilizan diferentes funciones, cada una con propiedades específicas.

En tareas de regresión, donde la variable objetivo es continua, una de las funciones más utilizadas es el error cuadrático medio (*Mean Squared Error*, MSE), que penaliza fuertemente los errores grandes. Su fórmula es:

$$\mathcal{L}_{MSE}(\mathcal{Y}, \hat{\mathcal{Y}}) = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Otra opción habitual en regresión es el error absoluto medio (*Mean Absolute Error*, MAE), que se define como:

$$\mathcal{L}_{MAE}(\mathcal{Y}, \hat{\mathcal{Y}}) = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

A diferencia del MSE, el MAE es más robusto frente a valores atípicos, ya que no eleva al cuadrado los errores. En contextos donde se desea combinar la sensibilidad del MSE con la robustez del MAE, se utiliza la función de pérdida de Huber, que cambia suavemente de cuadrática a lineal en torno a un umbral.

En problemas de clasificación binaria, como el abordado en este trabajo, la función de pérdida más adecuada es la entropía cruzada binaria (*binary cross-entropy*), la cual tiene una sólida interpretación probabilística y se corresponde con el logaritmo negativo de la verosimilitud de una distribución Bernoulli. Se define como:

$$\mathcal{L}(y, \hat{y}) = -[y \cdot \log(\hat{y}) + (1 - y) \cdot \log(1 - \hat{y})]$$

Esta fórmula puede interpretarse de la siguiente manera:

- Si el valor real es $y = 1$, entonces la función de pérdida se reduce a $-\log(\hat{y})$, penalizando fuertemente predicciones bajas de $\log(\hat{y})$, es decir, si el modelo predice una baja probabilidad de fallecimiento cuando en realidad sí ocurrió.
- Si $y = 0$, la pérdida es $-\log(1 - \hat{y})$, penalizando aquellas predicciones en las que el modelo asignó una alta probabilidad a un fallecimiento cuando no ocurrió.

El valor total de la pérdida sobre todo el conjunto de entrenamiento se calcula como el promedio de las pérdidas individuales:

$$\mathcal{L}_{tot} = \frac{1}{N} \sum_{i=1}^N \mathcal{L}(y_i, \hat{y}_i)$$

Esta función tiene varias ventajas: es continua, diferenciable, y especialmente adecuada cuando las salidas de la red son probabilidades generadas por una función sigmoide en la capa final. Además, tiene una interpretación probabilística sólida, ya que corresponde al logaritmo negativo de la verosimilitud de una distribución Bernoulli. Por lo tanto, minimizar esta pérdida es equivalente a maximizar la verosimilitud del modelo, un enfoque común en estadística y aprendizaje automático (Murphy, 2012).

Esta función penaliza más fuertemente los errores en las predicciones con alta confianza. A partir de esta pérdida, se calcula el gradiente respecto de cada peso y sesgo mediante el algoritmo de retropropagación (*backpropagation*), y se actualizan los parámetros siguiendo el método del descenso por gradiente:

$$w_{ij}^{(t+1)} = w_{ij}^{(t)} - \eta \cdot \frac{\partial \mathcal{L}}{\partial w_{ij}} ; b_j^{(t+1)} = b_j^{(t)} - \eta \cdot \frac{\partial \mathcal{L}}{\partial b_j}$$

donde η representa la tasa de aprendizaje, que regula la magnitud del ajuste en cada iteración. Este procedimiento se repite durante múltiples épocas, que son ciclos completos sobre el conjunto de entrenamiento. Sin embargo, para evitar el sobreajuste, se emplea una técnica denominada *early stopping*, que monitorea la pérdida sobre un conjunto de validación y detiene el entrenamiento si no se observa mejora luego de un número determinado de épocas consecutivas.

5.3 XGBoost

El algoritmo XGBoost es una implementación optimizada del método de *gradient boosting*, diseñado para maximizar la eficiencia computacional y el rendimiento predictivo en problemas de regresión y clasificación supervisada. Su principio fundamental consiste en construir secuencialmente un conjunto de modelos débiles —típicamente árboles de decisión— de manera que cada nuevo árbol intente corregir los errores cometidos por la suma de los anteriores.

En la iteración t , la predicción para un individuo i se calcula como la suma de las salidas de todos los árboles entrenados hasta ese momento:

$$\widehat{y}_i^{(t)} = \sum_{k=1}^K f_k(x_i), \quad f_k \in \mathcal{F}$$

donde $\mathcal{F}$ es el espacio de funciones que representan árboles de decisión con pesos w_j en las hojas:

$$\mathcal{F} = \{f(x) = w_{q(x)}\}$$

En este contexto, $q(x)$ es la función de asignación de una instancia a una hoja, y w_j el peso asociado a esa hoja.

El objetivo general del modelo en la iteración t es minimizar la siguiente función:

$$\mathcal{L}^{(t)} = \sum_{i=1}^n l\left(y_i, \widehat{y}_i^{(t-1)} + f_t(x_i)\right) + \Omega(f_t)$$

donde l es la función de pérdida y $\Omega(f_t)$ es un término de regularización que penaliza la complejidad del árbol para prevenir el sobreajuste:

$$\Omega(f) = \gamma T + \frac{1}{2} \lambda \sum_{j=1}^T w_j^2$$

Para optimizarla, XGBoost utiliza una expansión de Taylor de segundo orden, con el gradiente g_i y el Hessiano h_i de la función de pérdida:

$$\mathcal{L}^{(t)} \approx \sum_{i=1}^n \left[g_i f_t(x_i) + \frac{1}{2} h_i f_t^2(x_i) \right] + \Omega(f_t)$$

$$g_i = \frac{\partial l(y_i, \widehat{y_i^{(t-1)}})}{\partial \widehat{y_i^{(t-1)}}}, \quad h_i = \frac{\partial^2 l(y_i, \widehat{y_i^{(t-1)}})}{\partial \widehat{y_i^{(t-1)}}^2}$$

La solución óptima para el peso de cada hoja w_j^* se obtiene de:

$$w_j^* = - \frac{\sum_{i \in I_j} g_i}{\sum_{i \in I_j} h_i + \lambda}$$

y la ganancia obtenida al realizar una partición del nodo está dada por:

$$\mathcal{L}_{gi} = \frac{1}{2} \sum_{j=1}^T \frac{\left(\sum_{i \in I_j} g_i \right)^2}{\sum_{i \in I_j} h_i + \lambda} - \gamma T$$

Este procedimiento iterativo permite que XGBoost construya modelos robustos y de alta precisión, integrando técnicas como la regularización L_1 y L_2 , el manejo eficiente de datos faltantes y *shrinkage* (reducción del aprendizaje) para un mejor control del sobreajuste.

En el contexto de esta investigación, su capacidad para manejar datos tabulares con variables heterogéneas, modelar relaciones no lineales y abordar desequilibrios en la variable objetivo —en este caso, la ocurrencia o no de fallecimiento— lo convierten en una herramienta particularmente adecuada para la estimación de q_x y la construcción de tablas de mortalidad ajustadas por experiencia.

5.3 Suavizamiento Whittaker-Henderson

El método de suavizamiento de Whittaker-Henderson es una técnica utilizada para ajustar series de datos que presentan variabilidad irregular, con el objetivo de obtener una curva suavizada que conserve las tendencias subyacentes y reduzca el ruido. En el contexto actuarial, puede aplicarse para suavizar tasas de mortalidad q_x o cualquier función que dependa de la edad, evitando oscilaciones aleatorias que no corresponden a un patrón real.

El enfoque se basa en minimizar una función objetivo que equilibra dos criterios:

- Fidelidad “ F ” a los datos observados.
- Suavidad o Regularidad “ R ” de la curva ajustada.

Matemáticamente, se plantea como:

$$\min_z \{F(w_i, z_i) + \lambda R(z_i)\}$$

$$\min_z \left\{ \sum_{i=1}^n w_i (y_i - z_i)^2 + \lambda \sum_{i=1}^{n-m} (\Delta^m z_i)^2 \right\}$$

donde:

- y_i son los valores observados.
- z_i son los valores suavizados que queremos estimar.
- w_i son pesos que permiten dar mayor importancia a ciertos puntos (por ejemplo, ponderar por exposición en mortalidad).
- λ es el parámetro de suavizamiento. Si λ es pequeño, el ajuste sigue más de cerca los datos observados. Si λ es grande, la curva resultante será más suave.
- $\Delta^m z_i$ es la diferencia finita de orden m (usualmente $m=2$, que corresponde a suavizar la segunda derivada para controlar la curvatura).

La diferencia finita de segundo orden se define como:

$$\Delta^2 z_i = \Delta(z_{i+1} - z_i) = z_{i+2} - 2z_{i+1} + z_i$$

Por lo tanto, el problema de Whittaker busca un compromiso entre el error cuadrático ponderado:

$$\sum_{i=1}^n w_i (y_i - z_i)^2$$

y la penalización a la curvatura:

$$\lambda \sum_{i=1}^{n-2} (z_{i+2} - 2z_{i+1} + z_i)^2$$

El sistema resultante puede resolverse de manera eficiente mediante álgebra matricial.

$$(W + \lambda[k^T k])z = Wy$$

En donde:

- y vector de valores observados.
- W como la matriz diagonal de pesos.
- K como la matriz de diferencias finitas de orden m .

5.4 Método Delta para IC

El método Delta es una técnica estadística utilizada para aproximar la varianza de un estimador que es una función no lineal de otro estimador, a partir de la expansión en serie de Taylor de primer orden. Su aplicación permite obtener intervalos de confianza de forma analítica, evitando recurrir a métodos de remuestreo como bootstrap.

Sea $\hat{\theta}$ un estimador insesgado del parámetro θ , con varianza $\text{Var}(\hat{\theta})$. Si se define una cantidad derivada $g(\theta)$ mediante una función continua y diferenciable $g(\cdot)$, el método Delta establece que la varianza de $g(\hat{\theta})$ puede aproximarse por:

$$\text{Var}(g(\hat{\theta})) \approx [g'(\theta)]^2 \cdot \text{Var}(\hat{\theta})$$

Donde $g'(\theta)$ es la derivada de g evaluada en θ . Esta expresión proviene de la linealización de $g(\hat{\theta})$ en torno a θ .

$$g(\hat{\theta}) \approx g(\theta) + g'(\theta) \cdot (\hat{\theta} - \theta)$$

En el ámbito demográfico y actuarial, el método Delta resulta especialmente útil cuando se transforman tasas centrales de mortalidad m_x en probabilidades de fallecimiento q_x mediante relaciones no lineales. Por ejemplo, bajo el supuesto de variación exponencial en un intervalo de amplitud n , la transformación se expresa como:

$$q_x = 1 - e^{-n \cdot m_x}$$

Dado que q_x es función de m_x la varianza de $\hat{q}_x$ puede expresarse como:

$$\widehat{\text{Var}}(\hat{q}_x) \approx [n \cdot e^{-n\hat{m}_x}]^2 \cdot \widehat{\text{Var}}(\hat{m}_x)$$

Donde $\widehat{\text{Var}}(\hat{m}_x)$ puede estimarse a partir del modelo Binomial o de Poisson que describe los fallecimientos observados.

Una vez obtenida la varianza, gracias al teorema central del límite se puede construir un intervalo de confianza de la forma:

$$\hat{q}_x \pm z_{1-\alpha/2} \cdot \sqrt{\widehat{\text{Var}}(\hat{q}_x)}$$

Donde $z_{1-\alpha/2}$ es el valor que acumula $1 - \frac{\alpha}{2}$ de probabilidad en una distribución normal estándar:

$$\int_{-\infty}^{z_{1-\alpha/2}} \frac{e^{-\frac{x^2}{2}}}{\sqrt{2\pi}} dx = 1 - \frac{\alpha}{2}$$

La principal ventaja del método Delta radica en su sencillez y en que no requiere simulaciones, siendo válido bajo condiciones de normalidad asintótica y muestras suficientemente grandes. No obstante, al ser una aproximación de primer orden, su precisión puede disminuir en contextos con transformaciones fuertemente no lineales o tamaños muestrales reducidos.

5.5 Bandas de Wilson

Las bandas de Wilson se utilizan para estimar un intervalo de confianza para una proporción p (por ejemplo, una tasa de mortalidad q_x), ajustando el sesgo que aparece en las proporciones muestrales cuando la cantidad de observaciones es pequeña o cuando la proporción está cerca de 0 o 1.

A diferencia del intervalo de confianza clásico basado en la aproximación normal (Véase:

V: Supuesto l_x Exponencial

Se supone que l_x varía de forma exponencial en el intervalo $[x, x + n]$.

$$l_x = e^{a+bx}$$
$$m_x^n = \frac{d_x^n}{L_x^n} = \frac{l_x - l_{x+n}}{\int_x^{x+n} l_t dt}$$

Sustituyendo por la forma funcional de l_x se tiene:

$$m_x^n = \frac{e^{a+bx} - e^{a+b(x+n)}}{\int_x^{x+n} e^{a+bt} dt} = \frac{e^{a+bx}(1 - e^{bn})}{\frac{e^{a+bx}}{b}(e^{bn} - 1)} = -b$$

A su vez:

$$q_x^n = \frac{d_x^n}{l_x} = \frac{l_x - l_{x+n}}{l_x} = 1 - \frac{l_{x+n}}{l_x} = 1 - \frac{e^{a+b(x+n)}}{e^{a+bx}} = 1 - e^{bn}$$

Despejando b en función de m_x^n y sustituyendo en q_x^n :

$$q_x^n = 1 - e^{-n \cdot m_x^n}$$

VI: Teorema Central del Límite)

$$\hat{p} \pm z_{1-\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$$

el método de Wilson ajusta tanto el centro como la amplitud del intervalo, mejorando su precisión especialmente para tamaños de muestra pequeños.

Si:

- $\hat{p} = \frac{x}{n}$ es la proporción muestral (con x éxitos y n ensayos),

- $z_{1-\alpha/2}$ es el cuantil de la distribución normal estándar para el nivel de confianza deseado.

Luego los límites inferior y superior se calculan como:

Centro corregido:

$$Centro = \frac{\hat{p} + \frac{z^2}{2n}}{1 + \frac{z^2}{n}}$$

Margen de error corregido:

$$Margen = \frac{z}{1 + \frac{z^2}{n}} \sqrt{\frac{\hat{p}(1 - \hat{p})}{n} + \frac{z^2}{4n^2}}$$

Límites del intervalo:

$$Límite inferior = Centro - Margen, \quad Límite superior = Centro + Margen$$

Entonces:

$$\hat{p}_{inf} = \frac{\hat{p} + \frac{z^2}{2n} - z \sqrt{\frac{\hat{p}(1 - \hat{p})}{n} + \frac{z^2}{4n^2}}}{1 + \frac{z^2}{n}}, \quad \hat{p}_{sup} = \frac{\hat{p} + \frac{z^2}{2n} + z \sqrt{\frac{\hat{p}(1 - \hat{p})}{n} + \frac{z^2}{4n^2}}}{1 + \frac{z^2}{n}}$$

5.6 Métricas de Machine Learning

La evaluación cuantitativa del rendimiento de una red neuronal constituye un aspecto esencial en todo proceso de modelado, ya que permite comparar diferentes arquitecturas, ajustar hiperparámetros y determinar la capacidad generalizadora del modelo sobre datos no vistos (Goodfellow et al., 2016). En el caso particular de modelos aplicados a problemas de clasificación binaria, se emplean métricas específicas que permiten evaluar con precisión la capacidad del modelo para distinguir entre ambas clases.

Una de las herramientas más utilizadas es la matriz de confusión, que resume los aciertos y errores del modelo mediante cuatro componentes básicos:

- Verdaderos positivos (TP): instancias positivas correctamente clasificadas.
- Verdaderos negativos (TN): instancias negativas correctamente clasificadas.
- Falsos positivos (FP): instancias negativas clasificadas incorrectamente como positivas.

- Falsos negativos (FN): instancias positivas clasificadas incorrectamente como negativas.

A partir de esta matriz, se pueden derivar distintas métricas fundamentales para evaluar el rendimiento (Powers, 2011):

		Confusion Matrix	
Real Class	Real: 0	TN	FP
	Real: 1	FN	TP
		Predicted: 0	Predicted: 1
		Predicted Class	

Ilustración IV: Matriz de Confusión. Elaboración propia.

Precisión

La precisión mide la proporción de instancias que fueron clasificadas como positivas y que efectivamente lo eran:

$$\text{Precisión} = \frac{TP}{TP + FP}$$

Sensibilidad o Recall

También llamada tasa de verdaderos positivos (TPR), representa la capacidad del modelo para identificar correctamente a los positivos reales:

$$\text{Recall} = \frac{TP}{TP + FN}$$

Puntaje F1 (F1-Score)

El F1-score es la media armónica entre precisión y recall. Es especialmente útil cuando se desea un balance entre ambas métricas, como en el caso de clases desbalanceadas:

$$F_1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$

Accuracy

La accuracy (exactitud) mide la proporción total de predicciones correctas (tanto positivas como negativas):

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

Si bien es una métrica ampliamente utilizada, puede resultar engañosa en contextos donde las clases están desbalanceadas, ya que ignora la distribución de las clases en los datos (Saito & Rehmsmeier, 2015).

Curva ROC y AUC

Otra herramienta ampliamente empleada es la curva ROC (Receiver Operating Characteristic), que muestra la relación entre la tasa de verdaderos positivos (Recall) y la tasa de falsos positivos (FPR), definida como:

$$\text{FPR} = \frac{FP}{FP + TN}$$

La curva ROC se construye variando el umbral de clasificación y graficando los valores correspondientes de TPR y FPR. A partir de esta curva se calcula el área bajo la curva (AUC - Area Under the Curve), que representa la capacidad del modelo para discriminar entre clases. Un valor de AUC cercano a 1 indica un modelo altamente discriminativo, mientras que un valor cercano a 0.5 sugiere un desempeño similar al azar (Fawcett, 2006).

En contextos donde las clases están desbalanceadas, como es habitual en estudios biomédicos o aseguradores, se recomienda complementar la curva ROC con métricas como la precisión, el recall o la curva PR (precisión-recall), ya que ofrecen una representación más fiel del comportamiento del modelo frente a la clase minoritaria (Davis & Goadrich, 2006).

5.7 Synthetic Minority Over-sampling Technique

En el contexto del análisis de la mortalidad es común encontrarse con bases de datos desbalanceadas. Esto significa que una de las categorías de la variable objetivo —en este caso, la clase que representa a los asegurados fallecidos— se encuentra significativamente subrepresentada en comparación con la clase mayoritaria, es decir, quienes sobreviven. Esta desproporción impacta negativamente en el desempeño de los modelos predictivos, los cuales tienden a sesgarse hacia la clase dominante. Como consecuencia, se pueden obtener métricas globales aparentemente satisfactorias, mientras que se pierde precisión en la detección de los casos minoritarios, que en este tipo de aplicaciones resultan ser los más relevantes para la evaluación del riesgo actuarial (He & Garcia, 2009).

Frente a esta problemática, se han desarrollado diversas estrategias para abordar el desbalance. Una de ellas consiste en reducir la cantidad de observaciones de la clase

mayoritaria mediante submuestreo aleatorio, de forma tal que ambas clases queden equilibradas. No obstante, este enfoque implica descartar una gran cantidad de datos potencialmente valiosos, lo cual puede limitar la capacidad del modelo para generalizar. Otra alternativa es el sobre muestreo de la clase minoritaria, que implica replicar aleatoriamente registros ya existentes. Si bien este método conserva toda la información original, tiende a generar sobreajuste, dado que el modelo entrena reiteradamente sobre los mismos ejemplos (Fernández et al., 2018).

Una solución más robusta es SMOTE (Synthetic Minority Over-sampling Technique), propuesto por Chawla et al. (2002). A diferencia del sobre muestreo tradicional, SMOTE genera nuevas observaciones sintéticas de la clase minoritaria mediante interpolación lineal entre instancias reales. El algoritmo selecciona aleatoriamente una observación minoritaria x_i , identifica uno de sus k vecinos más cercanos x_j , y genera una nueva instancia x_{new} mediante la ecuación:

$$x_{\text{new}} = x_i + \delta \cdot (x_j - x_i)$$

Donde $\delta \sim U[0; 1]$ es un valor aleatorio extraído de una distribución uniforme. El nuevo punto se ubica en el espacio de características entre el punto original y su vecino, lo que permite cubrir regiones densas de la clase minoritaria sin replicar directamente los datos existentes. Este procedimiento se repite con diferentes vecinos y observaciones, generando así un conjunto de entrenamiento más equilibrado, con menor riesgo de sobreajuste y mejor capacidad de generalización en tareas como la predicción de fallecimientos.

Sin embargo, se reconoce que SMOTE puede introducir ruido si existe solapamiento entre clases en el espacio de atributos. Por esta razón, se suele complementar su aplicación con técnicas de validación cruzada o limpieza de instancias, con el fin de evaluar su impacto neto sobre el desempeño del modelo.

6. Metodología y Técnicas

Esta sección describe el procedimiento metodológico seguido para estimar tasas de mortalidad específicas de cartera y contrastarlas con la tabla regulatoria CB-H-2020. Se parte de la depuración y estandarización del dataset y de un análisis exploratorio para verificar su consistencia; luego se trata el desbalance de clases mediante SMOTE y ponderación. Con la base final se entrena un modelo supervisado (XGBoost, con RNA como contraste), se calibran probabilidades y se fijan umbrales por tramo etario. A partir de esas probabilidades se derivan tasas centrales y probabilidades de fallecimiento bajo supuesto exponencial, se construyen intervalos de confianza mediante el método Delta y se aplica suavizamiento Whittaker-Henderson. Finalmente, se comparan las tasas resultantes con la experiencia observada y con CB-H-2020, evaluando el desempeño con métricas como MAE y análisis por grupos de edad.

6.1 Análisis Exploratorio de Datos

La cartera analizada corresponde a registros individuales anonimizados provistos por una aseguradora que opera en el mercado chileno de rentas vitalicias. Para garantizar la comparabilidad con la tabla de referencia CB-H-2020, se excluyeron del dataset original los asegurados inválidos y las mujeres, dado que dicha tabla aplica únicamente a causantes y beneficiarios masculinos.

La variable objetivo es binaria e indica si el asegurado falleció durante el período anual considerado:

$$y_i = \begin{cases} 1 & \text{fallece} \\ 0 & \text{no fallece} \end{cases}$$

El análisis exploratorio se enfocó en caracterizar la composición del dataset y en verificar la consistencia de sus variables. En primer lugar, se examinó la distribución de Edad_Inicio, que refleja la frecuencia de asegurados según la edad al inicio de la cobertura. El histograma, acompañado de una curva suavizada, muestra una fuerte concentración entre los 65 y 80 años, lo que indica que la mayoría de los asegurados contrata el producto en edades cercanas a la jubilación o en etapas posteriores de la vida.

I:




Ilustración V: Distribución de la edad de inicio. Elaboración propia en base a la cartera. Véase: I: Análisis Exploratorio de Datos

En segundo lugar, se analizó la distribución de la variable objetivo muere (0 = sobrevive, 1 = fallece). El gráfico de frecuencias muestra un claro desbalance entre ambas categorías, con una proporción mucho mayor de sobrevivientes. Este aspecto resulta crítico para el entrenamiento de modelos predictivos, ya que tiende a sesgar las estimaciones hacia la clase mayoritaria y requiere aplicar técnicas de corrección como ponderación de clases o generación de observaciones sintéticas.




Ilustración VI: Distribución del sexo. Elaboración propia en base a la cartera.

Finalmente, se calculó la matriz de correlación entre las variables categóricas codificadas en forma binaria, representada mediante un mapa de calor. Este análisis permitió identificar relaciones lineales positivas o negativas entre predictores y evaluar la presencia de multicolinealidad. Como es esperable, categorías mutuamente excluyentes —por ejemplo, tipo de beneficiario o tipo de prima— presentan correlaciones negativas elevadas, mientras que en el caso de variables dicotómicas (como cónyuge sí/no) la correlación alcanza valores de -1 , reflejando su complementariedad exacta. El cálculo de la matriz de correlación se basa en la correlación de Pearson, que mide la fuerza y dirección de una relación lineal entre dos variables numéricas. Esta medida se aplica par a par entre las variables, resultando en una matriz cuadrada.

$$r_{XY} = \frac{\sum (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum (X_i - \bar{X})^2} \sqrt{\sum (Y_i - \bar{Y})^2}}$$

Donde:

- X_i e Y_i son los valores observados de las variables X e Y
- $\bar{X}$ y $\bar{Y}$ representan el promedio
- n es el número de observaciones
- $|r_{XY}| = 1$ denota correlación es perfecta, mientras que $r_{XY} = 0$ indica independencia.




Ilustración VII: Matriz de correlación. Elaboración propia en base a la cartera.

En síntesis, el análisis exploratorio permitió depurar el conjunto de datos y confirmar patrones clave en la composición de la cartera: predominio de edades avanzadas al inicio de la cobertura, fuerte desbalance entre sobrevivientes y fallecidos, y correlaciones esperables entre variables categóricas. Con esta base consistente, se procedió a la construcción de modelos predictivos, comenzando con redes neuronales artificiales y, posteriormente, con el algoritmo XGBoost, a fin de estimar probabilidades individuales de fallecimiento y derivar tasas de mortalidad ajustadas a la experiencia observada.

6.2 Redes Neuronales Artificiales

El primer enfoque de modelado fue un perceptrón multicapa (MLP) para clasificación binaria del evento anual “fallece / no fallece”. Un MLP es un modelo supervisado que transforma un vector de características tabulares en una probabilidad $\hat{p} \in [0,1]$ a través de capas lineales y funciones de activación no lineales.

Arquitectura y función de pérdida.

Se empleó una arquitectura compacta compuesta por una primera capa densa de 64 neuronas con activación ReLU, seguida de una capa de Dropout con probabilidad de desactivación del 30 %. Posteriormente, se incorporó una segunda capa oculta de 32 neuronas también con activación ReLU y otro Dropout del 30 %, finalizando con una capa de salida de una única neurona con activación sigmoide. La función ReLU (Rectified Linear Unit) se utilizó en las capas ocultas por su capacidad de acelerar el entrenamiento y mitigar la saturación de

gradientes, mientras que la activación sigmoide en la capa de salida permitió obtener directamente una probabilidad estimada $\hat{p}$ del evento de fallecimiento.

El mecanismo de Dropout, configurado en 30 %, cumple la función de desactivar aleatoriamente neuronas durante el entrenamiento, lo cual contribuye a reducir el sobreajuste y mejorar la capacidad de generalización del modelo. El entrenamiento se realizó minimizando la entropía cruzada binaria (véase la Sección 5.2 Redes Neuronales para un análisis detallado).

Para la optimización de parámetros se utilizó el algoritmo Adam, con una tasa de aprendizaje inicial $\eta = 0,001$. Además, se aplicó la técnica de early stopping con una paciencia de 20 iteraciones sobre la función de pérdida en validación, a fin de interrumpir el entrenamiento cuando el modelo dejaba de mejorar en el conjunto de validación y evitar así un ajuste excesivo a los datos de entrenamiento.

Preprocesamiento y balanceo de clases.

Dado que la variable de interés presenta un fuerte desbalance, se aplicó la técnica SMOTE, véase: 5.7 Synthetic Minority Over-sampling Technique, sobre el conjunto de entrenamiento, con el fin de generar observaciones sintéticas de la clase minoritaria. Este procedimiento permitió equilibrar las proporciones entre fallecidos y sobrevivientes durante el entrenamiento, reduciendo el sesgo del modelo hacia la clase mayoritaria y mejorando su capacidad para detectar eventos de fallecimiento.

Evaluación del desempeño y ajuste del umbral.

Dada la limitada disponibilidad de datos para edades individuales, se optó por organizar las predicciones en intervalos de cinco años —desde los 50 hasta los 105— definidos sobre la variable *Edad_Inicio*.

Cada individuo i con edad inicial e_i fue asignado a un b según la regla:

$$b = \left\lfloor \frac{e_i - 50}{5} \right\rfloor + 1, \quad e_i \in [50, 105]$$

De este modo, se conformaron intervalos $[a, a + 5)$ tales que:

$$B = \{[50, 55), [55, 60), \dots, [100, 105]\}$$

El desempeño de los modelos se evaluó en un esquema de entrenamiento, validación y prueba, utilizando las métricas previamente definidas en el marco teórico. Para la decisión sobre el umbral de clasificación se implementó la estrategia *Count-Match*, que ajusta el punto de corte de manera diferenciada por tramo etario. Para cada bin b , se buscó dentro de una grilla de valores

$$t \in [0.01, 0.99], \quad \Delta t = 0.01$$

el punto de corte que mejor alinearla la frecuencia predicha de fallecimientos con la proporción empíricamente observada. Formalmente, si denotamos por N_b la cantidad de observaciones en el tramo, la proporción predicha de fallecidos para un umbral t se expresa como

$$\hat{\pi}(b) = \frac{\#\{i \in b: \hat{p}_i \geq t\}}{N_b}$$

y la proporción real observada en dicho tramo como

$$\pi(b) = \frac{\#\{i \in b: y_i = 1\}}{N_b}$$

El umbral óptimo se definió entonces como

$$t^*(b) = \arg \min_{t \in [0.01, 0.99]} |\hat{\pi}(b) - \pi(b)|$$

Para los tramos con validación insuficiente, se adoptó un umbral de referencia global definido como la mediana de los umbrales estimados en los restantes tramos. Este procedimiento permitió calibrar las predicciones por edad de forma coherente con la experiencia empírica, respetando la frecuencia relativa de fallecimientos y evitando sesgos derivados de un único umbral global.

En suma, la red neuronal artificial permitió capturar relaciones no lineales entre las covariables y la probabilidad de fallecimiento, integrando técnicas de regularización, balanceo de clases mediante SMOTE y un criterio de calibración basado en *Count-Match*. Los resultados sirven como punto de referencia frente a otros métodos, particularmente XGBoost, que se desarrolla a continuación.

6.3 XGBoost

Diversos estudios respaldan la elección de XGBoost, destacando su rendimiento competitivo frente a otros algoritmos de aprendizaje supervisado en la predicción de eventos binarios en contextos actuariales y biométricos, gracias a su capacidad de generalización, eficiencia computacional y adaptabilidad a distintos volúmenes de datos (Chen & Guestrin, 2016; Richman et al., 2020). El modelo se fundamenta en la técnica de *gradient boosting*, que construye de manera secuencial un conjunto de árboles de decisión, donde cada nuevo árbol busca corregir los errores de sus predecesores. La lógica del algoritmo consiste en optimizar una función de pérdida —en este caso, la entropía cruzada binaria—, asignando mayor peso a las observaciones mal clasificadas y permitiendo capturar relaciones no lineales y complejas interacciones entre covariables.

Una característica distintiva de XGBoost es la incorporación de mecanismos de regularización (L_1 y L_2) que penalizan la complejidad de los árboles, contribuyendo a mejorar la capacidad de generalización y reducir el riesgo de sobreajuste. Asimismo, el parámetro de *shrinkage* o tasa de aprendizaje controla la magnitud de las actualizaciones en cada iteración, favoreciendo un equilibrio entre precisión y estabilidad. Estas propiedades lo convierten en

un método flexible y robusto, particularmente adecuado para el análisis de fenómenos biométricos, donde las relaciones entre covariables suelen ser heterogéneas y altamente no lineales.

En la implementación práctica sobre el dataset de asegurados, se definió la función de pérdida y se ajustaron los hiperparámetros principales: profundidad de los árboles (*max_depth*), número de estimadores (*n_estimators*) y tasa de aprendizaje (*learning_rate*). Para optimizar su configuración se utilizó validación cruzada con búsqueda aleatoria (*RandomizedSearchCV*) y *early stopping*, interrumpiendo el entrenamiento cuando la pérdida de validación dejaba de mejorar. De esta forma, se redujo el riesgo de sobreajuste y se optimizaron los tiempos de cómputo.

El desempeño de cada configuración se evaluó con las métricas previamente definidas en el marco teórico (véase 5.6 Métricas de Machine Learning), incluyendo precisión, recall, F1-score y AUC. Finalmente, se aplicó un ajuste del umbral de decisión mediante el conteo de coincidencias *Count-Match* entre predicciones y valores observados, con el objetivo de maximizar la utilidad práctica del clasificador en el contexto actuarial.

6.4 Tasas de Mortalidad

La construcción de las tasas de mortalidad constituyó la etapa final del proceso metodológico, orientada a transformar las predicciones individuales generadas por los modelos en una estructura agregada coherente con la práctica actuarial. Para ello, siguieron los siguientes pasos.

Predicciones individuales

Tanto la Red Neuronal Artificial (RNA) como XGBoost (XGB) produjeron, para cada asegurado i , una probabilidad de fallecimiento en el período de observación, denotada por $\hat{p}_i$.

Ajuste de umbrales con Count-Match

Sobre el conjunto de validación, y para cada tramo etario b , se implementó la estrategia *Count-Match*. El objetivo fue determinar un umbral $t^*(b)$ que equilibrara la proporción de individuos clasificados como fallecidos con la proporción empírica observada en dicho tramo. Así, la clasificación de la predicción binaria será $\hat{y}_i = 1$ para todo i que cumple $\hat{p}_i \geq t^*(b)$.

Clasificación en el conjunto de prueba

Con los umbrales $t^*(b)$ obtenidos en validación, se procedió a clasificar a los individuos del conjunto de prueba. De esta manera se obtuvieron, para cada tramo b , los conteos predichos de muertes $d(b)_{pred}$, comparables con los valores observados $d(b)_{real}$.

Cálculo de tasas centrales de mortalidad

Finalmente, se calcularon las tasas centrales de mortalidad y las probabilidades de fallecer en el intervalo, a partir de los fallecimientos reales y predichos y de los expuestos E_x^n .

Para cada tramo b de tamaño n , se calculó la tasa central de mortalidad:

$$m_x^n = \frac{d_x^n}{E_x^n} = \frac{d_x^n}{L_x^n}$$

En cada tramo b del conjunto de prueba, el número de fallecimientos observados se obtuvo como

$$d(b)_{real} = \sum_{i \in b} 1 \{y_i = 1\}$$

mientras que el conteo predicho por cada modelo se calculó aplicando el umbral etario $t^*(b)$ (definido en validación) a las probabilidades individuales:

$$d(b)_{pred} = \sum_{i \in b} 1 \{\hat{p}_i \geq t^*(b)\}$$

El total de expuestos (asegurados en el tramo) es

$$N(b) = \sum_{i \in b} 1$$

Para estimar la exposición efectiva se utilizó el esquema clásico de supuestos fraccionarios, considerando que los fallecimientos ocurren en promedio a la mitad del intervalo, $k = \frac{1}{2}$

$$E(b) = N(b) - (1 - k) d(b)$$

De esta forma, cada fallecido aporta medio año de exposición, mientras que los sobrevivientes aportan un año completo.

Con estos insumos, las tasas centrales y probabilidades por tramo se construyeron como ya indicado, manteniendo el mismo denominador $E(b)$ para las tasas centrales reales y las predichas.

Luego se procedió a convertir las tasas centrales de mortalidad, m_x^n , en probabilidades de muerte q_x^n (véase: 5.1 Tasas Centrales de Mortalidad)

$$q_x^n = 1 - e^{-n \cdot m_x^n}$$

Este procedimiento permitió obtener, para cada intervalo de edad, las probabilidades de fallecimiento tanto para el modelo predictivo $q_x^{n,model}$ como para la experiencia observada $q_x^{n,real}$. Se cercioró que las tasas de mortalidad sean no decrecientes conforme avanza la edad.

Intervalos de confianza por el método Delta

A cada q_x observado se le asociaron intervalos de confianza al 95 % aplicando el método Delta, que ajusta la varianza en la transformación de m_x a q_x . (véase: 5.4 Método Delta para IC).

Comparación con la tabla CB-H-2020

Debido a que las q_x calculadas previamente se reportan por tramos de amplitud n , se requiere obtener la probabilidad de fallecimiento por tramo de la tabla regulatoria, $q_x^{n,table}$

Enfoque producto:

$$q_x^{n,table} = 1 - p_x^n = 1 - \prod_{t=0}^{n-1} p_{x+t} = 1 - \prod_{t=0}^{n-1} (1 - q_{x+t})$$

Enfoque por l_x (adoptado en este trabajo):

Sea l_x la población sobreviviente a la edad x con $l_{x_0} = 100.000$ en la edad inicial del rango de la tabla, y evolución anual dada por:

$$l_{x+1} = l_x \cdot (1 - q_x)$$

Entonces, la probabilidad por tramo se obtiene de forma exacta como:

$$q_x^{n,table} = 1 - \frac{l_{x+n}}{l_x}$$

Ambas formulaciones son equivalentes en teoría; sin embargo, en la práctica el cómputo vía l_x evita el arrastre de errores de redondeo que puede introducirse al multiplicar sucesivamente $1 - q_x$ dentro de cada tramo. Por este motivo, en este trabajo se optó por calcular q_x a partir de l_x .

Suavizado con Whittaker-Henderson

Con el fin de reducir la variabilidad aleatoria y preservar tendencias, se aplicó suavizamiento Whittaker-Henderson sobre la serie q_x del modelo. El parámetro de suavizado λ se seleccionó mediante búsqueda en grilla, minimizando el MAE ponderado por expuestos respecto de q_x real en el conjunto de prueba:

$$MAE_p = \frac{\sum_b w_b |q_{x,pred}(b) - q_{x,real}(b)|}{\sum_b w_b}$$

(Véase: 5.3 Suavizamiento Whittaker-Henderson)

6.5 Resultados

Los resultados obtenidos permiten evaluar el desempeño de los dos modelos propuestos — XGBoost y Redes Neuronales Artificiales— en la predicción de la probabilidad de fallecimiento. Para ello, se presentan las métricas de accuracy, precisión, recall, F1-score y AUC calculadas sobre el conjunto de prueba. Estas métricas ofrecen una visión integral del balance entre aciertos y errores de clasificación, así como de la capacidad discriminante de cada modelo. La tabla siguiente resume los valores alcanzados, brindando un punto de partida para discutir las ventajas y limitaciones relativas de cada enfoque en el contexto actuarial.

model	metric	value
NN	Accuracy	0,83842
NN	Precision	0,668276
NN	Recall	0,658452
NN	F1	0,663328
NN	AUC (calibrado)	0,8994
XGB	Accuracy	0,830477
XGB	Precision	0,649762
XGB	Recall	0,648076
XGB	F1	0,648918
XGB	AUC (calibrado)	0,896904

Tabla I: Métricas de machine learning. Elaboración propia. Para detalles sobre el cálculo de cada métricas refiérase a 5.6 Métricas de Machine Learning




Ilustración XIII: Comparación de métricas NN vs XGB. Elaboración propia.

NN	Pred 0	Pred 1
Real 0	6.499	756
Real 1	790	1.523
XGB	Pred 0	Pred 1
Real 0	6.447	808
Real 1	814	1.499

Tabla II: Matriz de confusión. Elaboración propia

AGE_BIN	AGE_LO	muer	expuestos	N(b)	mueres_pred_nn	mueres_pred_xgb	qx_real	qx_tabla_lx	qx_model_nn	qx_model_xgb
50-54	50	1	107	106,5	1	6	0,045863329	0,014394876	0,044348593	0,105420796
55-59	55	3	93	91,5	2	2	0,151202321	0,023388882	0,100181413	0,110753167
60-64	60	13	327	320,5	12	11	0,18356511	0,034731161	0,172146167	0,165811014
65-69	65	113	1526	1469,5	108	92	0,319198514	0,05644186	0,307007534	0,31811652
70-74	70	298	1919	1770	248	358	0,569069265	0,099658681	0,506089017	0,60651565
75-79	75	469	1359	1124,5	426	413	0,875739024	0,159945553	0,845614726	0,828154469
80-84	80	456	909	681	520	453	0,964846026	0,265145604	0,978098498	0,955635253
85-89	85	439	589	369,5	442	457	0,997369181	0,413293386	0,999433713	1
90-94	90	338	374	205	346	341	0,999737144	0,587221941	0,999993308	1
95-99	95	131	137	71,5	136	136	0,999894925	0,762079398	0,999993308	1
100-104	100	33	33	16,5	33	33	0,9999546	0,899981225	0,999993308	1

Tabla III: Valores de las tasas de mortalidad por tramo. Elaboración propia

Luego para cada modelo se comparan a nivel tramo las curvas q_x^{real} (con IC Delta), q_x^{model} , $q_x^{model WH}$, q_x^{table}




Ilustración IX: Modelo de NN, comparación de q_x . Elaboración propia




Ilustración X: Modelo de XGB, comparación de q_x . Elaboración propia




Ilustración XI: Modelos NN y XGB, comparación de q_x . Elaboración propia

Se procede a compara los errores de cada modelo y de la tabla de referencia.




Ilustración XII: Comparación de MAE ponderado. Elaboración propia




Ilustración XIII: Comparación de error absoluto por modelo. Elaboración propia

7. Fuentes de Información

La fuente de datos utilizada en este trabajo corresponde a información privada provista por una importante compañía aseguradora con operaciones en Chile. Se trata de una base de asegurados pertenecientes al ramo de rentas vitalicias, que contiene características demográficas y contractuales relevantes para el análisis de la mortalidad. Entre las variables principales se incluyen la edad de inicio de la cobertura, el año de proyección considerado y un indicador de fallecimiento en el período, lo que permite vincular la experiencia observada con la estimación de probabilidades de muerte.

8. Consideraciones Éticas

Si bien la información utilizada es de carácter privado, se garantiza que no contiene datos sensibles ni identificadores que permitan la individualización de asegurados o pólizas. Todos los registros fueron previamente anonimizados por la compañía aseguradora, de modo que no es posible la reidentificación de los individuos.

El uso de estos datos se realizó exclusivamente con fines de investigación académica, sin ningún propósito comercial. Asimismo, el tratamiento de la información siguió principios de confidencialidad y buenas prácticas en el manejo de datos, resguardando la privacidad de los asegurados y cumpliendo con estándares éticos vigentes en estudios actuariales y estadísticos.

9. Conclusión

El procedimiento implementado permitió desarrollar y evaluar modelos de predicción de mortalidad basados en Extreme Gradient Boosting (XGBoost) y en redes neuronales artificiales (RNA), complementado con técnicas de calibración y suavizamiento de tasas mediante el método de Whittaker. Si bien las métricas globales de clasificación —como precisión, recall y F1-score— no alcanzaron valores óptimos, el análisis de las tasas específicas por edad q_x evidenció un ajuste superior del modelo respecto a la tabla de mortalidad utilizada como referencia. En particular, las tasas de mortalidad estimadas q_x^{model} reproducen de manera más cercana el comportamiento de las tasas reales observadas q_x^{real} , reduciendo el error absoluto medio y mostrando menor dispersión.

Estos resultados indican que, más allá del rendimiento global como clasificadores, tanto XGBoost como RNA logran capturar patrones relevantes de mortalidad por edad que resultan útiles para la construcción de tablas adaptadas a la experiencia de la cartera analizada. Esto es consistente con el objetivo actuarial del estudio, al permitir disponer de insumos más representativos para la estimación de primas y reservas.

En relación con los objetivos planteados, los modelos de *machine learning* desarrollados lograron estimar probabilidades de fallecimiento específicas de cartera con un menor error absoluto medio que la tabla de mortalidad CB-H-2020, validando la hipótesis principal del

estudio. Asimismo, se observaron diferencias estadísticamente significativas en ciertos grupos etarios, y si bien XGBoost mostró una mayor robustez y estabilidad, las RNA alcanzaron métricas levemente superiores en algunos indicadores (como el MAE), lo que respalda parcialmente las hipótesis secundarias. En conjunto, estos hallazgos confirman la viabilidad de integrar técnicas de aprendizaje automático al proceso actuarial de construcción de tablas de mortalidad, complementando los métodos regulatorios vigentes y proporcionando insumos más representativos para la estimación de primas y reservas.

No obstante, el estudio presenta ciertas limitaciones. Entre ellas, la dependencia de la calidad y representatividad de la base de datos disponible, la posible presencia de sesgos en la información histórica y la elección de un número restringido de algoritmos predictivos, sin realizar una comparación exhaustiva con otros enfoques estadísticos o de *machine learning*. Asimismo, la calibración se efectuó sobre un período temporal específico, por lo que la estabilidad de los modelos ante cambios estructurales en las tendencias de mortalidad no ha sido evaluada de forma integral.

En este sentido, futuras investigaciones podrían ampliar el análisis incorporando distintos horizontes temporales y carteras más amplias y diversificadas, ya que el presente estudio se limitó a una única cartera y a un producto específico de rentas vitalicias. Si bien se exploraron distintos enfoques —incluyendo redes neuronales LSTM y GRU—, estos no superaron en forma consistente los dos modelos propuestos, aunque sí evidenciaron un potencial relevante para capturar dinámicas no lineales complejas. Por ello, líneas futuras de investigación podrían enfocarse en variantes más avanzadas de RNA o en arquitecturas híbridas que combinen la capacidad predictiva del machine learning con técnicas actuariales tradicionales, con el fin de optimizar la modelización de la mortalidad y su aplicación en la estimación de primas y reservas.

10. Referencias Bibliográficas

Bergeron-Boucher, M., Canudas-Romo, V., Oeppen, J., & Vaupel, J. W. (2017). Coherent modeling of the mortality of the world's populations. *Demography*, 54(4), 1361–1378. <https://doi.org/10.1007/s13524-017-0595-1>

Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE: Synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research*, 16, 321–357. <https://doi.org/10.1613/jair.953>

Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. En *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (pp. 785–794). ACM. <https://doi.org/10.1145/2939672.2939785>

Davis, J., & Goadrich, M. (2006). The relationship between precision-recall and ROC curves. En *Proceedings of the 23rd International Conference on Machine Learning* (pp. 233–240). ACM. <https://doi.org/10.1145/1143844.1143874>

Fawcett, T. (2006). An introduction to ROC analysis. *Pattern Recognition Letters*, 27(8), 861–874. <https://doi.org/10.1016/j.patrec.2005.10.010>

Géron, A. (2019). *Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow: Concepts, tools, and techniques to build intelligent systems* (2.^a ed.). O'Reilly Media.

Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep learning*. MIT Press. <https://www.deeplearningbook.org/>

Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The elements of statistical learning: Data mining, inference, and prediction* (2.^a ed.). Springer. <https://doi.org/10.1007/978-0-387-84858-7>

He, H., & Garcia, E. A. (2009). Learning from imbalanced data. *IEEE Transactions on Knowledge and Data Engineering*, 21(9), 1263–1284. <https://doi.org/10.1109/TKDE.2008.239>

Lee, R. D., & Miller, T. (2001). Evaluating the performance of the Lee–Carter method for forecasting mortality. *Demography*, 38(4), 537–549. <https://doi.org/10.1353/dem.2001.0036>

LeCun, Y., Bottou, L., Orr, G. B., & Müller, K. R. (2012). Efficient backprop. En G. Montavon, G. B. Orr, & K. R. Müller (Eds.), *Neural networks: Tricks of the trade* (pp. 9–48). Springer. https://doi.org/10.1007/978-3-642-35289-8_3

Liu, J., Wu, J., Liu, S., Li, M., Hu, K., & Li, K. (2021). Predicting mortality of patients with acute kidney injury in the ICU using XGBoost model. *PLOS ONE*, 16(2), e0246306. <https://doi.org/10.1371/journal.pone.0246306>

Murphy, K. P. (2012). *Machine learning: A probabilistic perspective*. MIT Press.

Nair, V., & Hinton, G. E. (2010). Rectified linear units improve restricted Boltzmann machines. En *Proceedings of the 27th International Conference on Machine Learning (ICML-10)* (pp. 807–814). Omnipress.

Ortega, A. (1987). *Tablas de mortalidad* (Serie E, N.º 1004). Centro Latinoamericano de Demografía.

Powers, D. M. (2011). Evaluation: From precision, recall and F-measure to ROC, informedness, markedness & correlation. *Journal of Machine Learning Technologies*, 2(1), 37–63.

Rumelhart, D. E., Hinton, G. E., & Williams, R. J. (1986). Learning representations by back-propagating errors. *Nature*, 323(6088), 533–536. <https://doi.org/10.1038/323533a0>

Saito, T., & Rehmsmeier, M. (2015). The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. *PLOS ONE*, 10(3), e0118432. <https://doi.org/10.1371/journal.pone.0118432>

Society of Actuaries. (s.f.). Life insurance and annuities: Practice note on experience studies. Recuperado el 15 de junio de 2025, de <https://www.soa.org/resources/research-reports/2021/practice-note-life-annuity-experience-studies/>

I: Análisis Exploratorio de Datos

```
import os
import math
import pandas as pd
import numpy as np
import seaborn as sns
import matplotlib.pyplot as plt

sns.set(style="whitegrid")

# ===== CONFIG =====
FILE_PATH = r"C:\Users\Rafael\Desktop\UBA\Tesis_Actua-
rial\MET_DATA\CODE"
FILE_NAME = "DF_TOTAL.csv"
OUT_DIR = os.path.join(FILE_PATH, "EDA_PYTHON")
os.makedirs(OUT_DIR, exist_ok=True)

# ===== LOAD & FILTER =====
def load_data(path, file_name, sep=";"):
    df = pd.read_csv(os.path.join(path, file_name), sep=sep)
    df.columns = df.columns.str.strip()

    # Edad_Inicio a numérico
    if "Edad_Inicio" not in df.columns:
        raise ValueError("No se encontró la columna 'Edad_Inicio' en el CSV.")
    df["Edad_Inicio"] = pd.to_numeric(df["Edad_Inicio"], errors="coerce")

    # Filtro: quitar inválidos (Invalidez==1) y mujeres (BEN_SEXO_F==1) si las col existen
    mask = pd.Series(True, index=df.index)
    if "Invalidez" in df.columns:
        mask &= (df["Invalidez"] != 1)
    if "BEN_SEXO_F" in df.columns:
        mask &= (df["BEN_SEXO_F"] != 1)

    df = df[mask].copy()
    df = df.dropna(subset=["Edad_Inicio"])

    # Guardar dataset filtrado
    out_csv_filtered = os.path.join(OUT_DIR, "DF_filtrado_sin_invali-
dos_y_mujeres.csv")
    df.to_csv(out_csv_filtered, index=False)
    print("✓ Dataset filtrado guardado en:", out_csv_filtered)
    return df

# ===== AGE_BINS =====
def make_bins_from_zero(series, width=5, max_cap=115):
    x_max = float(series.max())
    top = min(max_cap, width * math.ceil(max(1, x_max) / width))
    bins = list(range(0, int(top) + width, width))
    labels = [f"{i}-{i+width-1}" for i in bins[:-1]]
    return bins, labels

# ===== GRAPHS =====
def plot_age_distribution(df, out_dir):
    bins, labels = make_bins_from_zero(df["Edad_Inicio"], width=5)
    df = df.copy()
    df["Grupo_Edad"] = pd.cut(df["Edad_Inicio"], bins=bins, labels=la-
bels, right=False, include_lowest=True)
```

II: XGBoost Model

```
# =====
# XGBoost + Umbral por bin (count-match) + Suavizado (WH)
# qx: Real vs Modelo vs Tabla (IC por Delta Method)
# =====

import os
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import joblib
import xgboost as xgb
from scipy.stats import norm

from sklearn.model_selection import train_test_split, Random-
izedSearchCV
from sklearn.metrics import (
    classification_report, confusion_matrix,
    roc_auc_score, roc_curve, ConfusionMatrixDisplay,
    precision_score, recall_score, f1_score, average_precision_score
)
from sklearn.isotonic import IsotonicRegression
from scipy import sparse
from scipy.sparse.linalg import spsolve
from xgboost import XGBClassifier

# ===== CONFIG =====
MAIN_PATH = r"C:\Users\Rafael\Desktop\UBA\Tesis_Actuar-
ial\MET_DATA\CODE"
OUTPUT_DIR = os.path.join(MAIN_PATH, "OUTPUT_MODEL_XGBOOST_PABLO")
INPUT_FILE = "DF_TOTAL_CB.csv"
MORT_TABLE_FILE = "MORT_TABLE_CB_H 2020.csv"
os.makedirs(OUTPUT_DIR, exist_ok=True)

OBJ_UMBRAL = "COUNT_MATCH"
USE_WHITTAKER = True

# ===== BINS =====
BIN_WIDTH = 5
AGE_MIN = 50
AGE_MAX = 105
AGE_BINS = list(range(AGE_MIN, AGE_MAX + BIN_WIDTH, BIN_WIDTH))
AGE_LABELS = [f"{AGE_BINS[i]}-{AGE_BINS[i+1]-1}" for i in
range(len(AGE_BINS)-1)]

# ===== IC_DELTA (para q = 1 - exp(-n*m)) =====
def delta_ci(d, L, n, alpha=0.05):
    d = np.asarray(d, dtype=float)
    L = np.asarray(L, dtype=float)
    Ls = np.maximum(L, 1.0)
    z = norm.ppf(1 - alpha/2)
    mhat = d / Ls
    qhat = 1.0 - np.exp(-n * mhat)
    qhat = np.clip(qhat, 1e-12, 1 - 1e-12)
    se = n * (1.0 - qhat) * np.sqrt(np.maximum(qhat * (1.0 - qhat) /
Ls, 0.0))
    low = np.clip(qhat - z * se, 0.0, 1.0)
    high = np.clip(qhat + z * se, 0.0, 1.0)
    return qhat, low, high

# ===== WHITTAKER-HENDERSON =====
def whittaker_henderson(y, w, lmbd):
    y = np.asarray(y, dtype=float); w = np.asarray(w, dtype=float)
```

III: SMOTE

```
import pandas as pd
import os
import seaborn as sns
import matplotlib.pyplot as plt
from imblearn.over_sampling import SMOTE
from collections import Counter

MAIN_PATH = r"C:\Users\Rafael\Desktop\UBA\Tesis_Actuarial\MET_DATA\CODE"

# Cargar los datos
def load_data(file_name, sep=";"):
    df = pd.read_csv(os.path.join(MAIN_PATH, file_name), sep=sep)
    df['Edad_Inicio'] = df['Edad_Inicio'].astype(str)
    df['Edad_Inicio'] = df['Edad_Inicio'].str.replace(',', '.', regex=False)
    df['Edad_Inicio'] = pd.to_numeric(df['Edad_Inicio'], errors='coerce')
    return df

df = load_data("df_merged.csv", sep=";")
X = df.drop('muere', axis=1)
y = df['muere']

# Separar variables
numeric_var = ['Edad_Inicio']
cat_var = [col for col in X.columns if col not in numeric_var]
X_cat = X[cat_var].reset_index(drop=True)
X_processed = pd.concat([X[numeric_var], X_cat], axis=1)

# Aplicar SMOTE
smote = SMOTE(random_state=42)
X_resampled, y_resampled = smote.fit_resample(X_processed, y)

# Crear DF
X_resampled_df = pd.DataFrame(X_resampled, columns=X.columns)
y_resampled_df = pd.DataFrame(y_resampled, columns=['muere'])
df_resampled = pd.concat([X_resampled_df, y_resampled_df], axis=1)
df_resampled.to_csv(os.path.join(MAIN_PATH, "df_SMOTE.csv"), sep=";", decimal=".", index=False)
```

III: Función ReLU

```
import numpy as np
import matplotlib.pyplot as plt

# Define the ReLU function
def ReLU(z):
    return np.maximum(0,z)

# Generate values for z
z = np.linspace(-10, 10, 400)
y = ReLU(z)

# Plot the sigmoid function
plt.figure(figsize=(8, 5))
plt.plot(z, y, label=r'$ReLU(z) = \max(0,z)$', color='blue')
plt.title('ReLU Function')
plt.xlabel('z')
plt.ylabel(r'$ReLU(z)$')
plt.legend()
plt.grid(True)
plt.tight_layout()
plt.show()
```

IV: Función Sigmoide

```
import numpy as np
import matplotlib.pyplot as plt

# Define the sigmoid function
def sigmoid(z):
    return 1 / (1 + np.exp(-z))

# Generate values for z
z = np.linspace(-10, 10, 400)
y = sigmoid(z)

# Plot the sigmoid function
plt.figure(figsize=(8, 5))
plt.plot(z, y, label=r'$\sigma(z) = \frac{1}{1 + e^{-z}}$', color='blue')
plt.axhline(0.5, color='red', linestyle='--', label='umbral = 0.5')
plt.title('Sigmoid Function')
plt.xlabel('z')
plt.ylabel(r'$\sigma(z)$')
plt.legend()
plt.grid(True)
plt.tight_layout()
plt.show()
```

V: Supuesto l_x Exponencial

Se supone que l_x varía de forma exponencial en el intervalo $[x, x + n)$.

$$l_x = e^{a+bx}$$

$$m_x^n = \frac{d_x^n}{L_x^n} = \frac{l_x - l_{x+n}}{\int_x^{x+n} l_t dt}$$

Sustituyendo por la forma funcional de l_x se tiene:

$$m_x^n = \frac{e^{a+bx} - e^{a+b(x+n)}}{\int_x^{x+n} e^{a+bt} dt} = \frac{e^{a+bx}(1 - e^{bn})}{\frac{e^{a+bx}}{b}(e^{bn} - 1)} = -b$$

A su vez:

$$q_x^n = \frac{d_x^n}{l_x} = \frac{l_x - l_{x+n}}{l_x} = 1 - \frac{l_{x+n}}{l_x} = 1 - \frac{e^{a+b(x+n)}}{e^{a+bx}} = 1 - e^{bn}$$

Despejando b en función de m_x^n y sustituyendo en q_x^n :

$$q_x^n = 1 - e^{-n \cdot m_x^n}$$

VI: Teorema Central del Límite

La distribución de la media muestral de variables aleatorias independientes e idénticamente distribuidas (i.i.d.) tiende a una distribución normal conforme el tamaño muestral crece, independientemente de la distribución original de la población.

Sea $\{X_1, X_2, \dots, X_n\}$ una secuencia de variables aleatorias i.i.d. en donde cada variable aleatoria tiene un comportamiento dicotómico, luego la variable aleatoria se puede modelar mediante una distribución Bernoulli de parámetro p , es decir, $X_i \sim \text{Bernoulli}(p)$

En dónde su función de probabilidad:

$$P(X = x) = p^x(1 - p)^{1-x}, \quad x = 0, 1$$

Luego el momento absoluto de orden 1:

$$E[X] = \sum_{x=0}^1 x P(x) = p$$

Y su momento central de orden 2:

$$\text{VAR}[X] = \sum_{x=0}^1 (x - E[X])^2 P(x) = p(1 - p)$$

Definimos la proporción muestral como:

$$\hat{p} = \frac{1}{n} \sum_{i=1}^n X_i$$

la cual es un estimador insesgado de p con varianza

$$\text{Var}(\hat{p}) = \frac{p(1-p)}{n}$$

El Teorema Central del Límite establece que, para n suficientemente grande, la distribución de la proporción muestral se aproxima a una normal:

$$\hat{p} \approx \mathcal{N}\left(p, \frac{p(1-p)}{n}\right)$$

De forma equivalente, si se estandariza la variable $\hat{p}$ mediante:

$$Z = \frac{\hat{p} - p}{\sqrt{\frac{p(1-p)}{n}}}$$

Luego:

$$Z \rightarrow N(0,1) \text{ cuando } n \rightarrow \infty$$

Este resultado es fundamental para la inferencia estadística, ya que permite aproximar la distribución de estimadores de proporciones —y, por extensión, de medias— a una normal estándar, facilitando el cálculo de probabilidades, intervalos de confianza y contrastes de hipótesis, incluso cuando la distribución original de la población no es normal.

VII: Gompertz–Makeham

Se presenta la derivación de la función de supervivencia bajo el modelo de Gompertz–Makeham, punto de partida para la construcción de funciones de sobrevivientes l_x .

La fuerza de mortalidad se define como:

$$\mu(x) = a + ce^{bx}, \quad a, b, c > 0.$$

La función de supervivencia $S(x)$ puede interpretarse como la probabilidad de que el tiempo de vida T de un individuo exceda una cierta edad x :

$$P(T > x) = S(x) = e^{-\int_0^x \mu(t) dt}$$

Al integrar la fuerza de mortalidad obtenemos:

$$\int_0^x \mu(t) dt = \int_0^x a + ce^{bt} dt = ax + \frac{c}{b}(e^{bx} - 1)$$

Luego, la función de supervivencia bajo Gompertz–Makeham resulta:

$$S(x) = e^{-ax + \frac{c}{b}(e^{bx} - 1)}$$

Entonces:

$$l_x = l_0 S(x) = l_0 e^{-ax + \frac{c}{b}(e^{bx} - 1)}$$

VII: Código Área curva l_x

```
# ===== GLOBAL_VARIABLES =====
MAIN_PATH = r"C:\Users\Rafael\Desktop\UBA\Tesis_Actuarial\MET_DATA\CODE"
OUT_FILENAME = "Lx_AREA_Greville_Keyfitz.png"
# =====

import os
import numpy as np
import matplotlib.pyplot as plt

# ----- dominio y tramo -----
edad_min, edad_max = 0, 105
x, n = 35, 20
k_x = 0.5
dpi = 300

# ----- curva  $l_x$  (suave tipo Gompertz/Makeham-like para ilustración) -----
def lx_gompertz_like(t, a=5.5e-5, b=0.095, c=1.5e-4):
    return np.exp(-a*t - c*(np.exp(b*t)-1.0)/b)

ages = np.linspace(edad_min, edad_max, 2000)
lx = lx_gompertz_like(ages)
lx = lx / lx[0] # normalizar a 1 en x=0

# helpers para evaluar  $l$  en edades exactas
def ell(age):
    return float(np.interp(age, ages, lx))

def d5(age):
    return ell(age) - ell(age + 5)

# ----- Greville-Keyfitz:  $\{l_x\}^5$  y  $\{l_x\}^n$  como suma de quinquenios -----
def five_Lx_greville(x0):
    """
    Aproximación de Greville-Keyfitz para  $\{l_x\}^5$ .
    Requiere  $l_{x0-5}$ ,  $l_{x0}$ ,  $l_{x0+5}$ ,  $l_{x0+10}$  para formar
     $\{d_{x0-5}\}^5$  y  $\{d_{x0+5}\}^5$ .
    """
    # chequeos de borde (si no hay margen, usamos el término disponible sin corrección)
    have_left = (x0 - 5) >= edad_min
    have_right = (x0 + 10) <= edad_max

    ell_x = ell(x0)
    ell_x5 = ell(x0 + 5)

    d5_xm5 = d5(x0 - 5) if have_left else 0.0
    d5_xp5 = d5(x0 + 5) if have_right else d5(x0)

    term_trap = (5.0/2.0) * (ell_x + ell_x5)
    term_corr = (5.0/24.0) * (d5_xp5 - d5_xm5)
    return term_trap + term_corr

def n_Lx_greville(x0, n_years):
    """
    Suma de bloques quinquenales por Greville-Keyfitz para obtener
     $\{l_x\}^n$ .
    Requiere n múltiplo de 5.
    """
```

